

**UNIVERSIDAD ESTATAL PENÍNSULA DE
SANTA ELENA**

FACULTAD DE SISTEMAS Y TELECOMUNICACIONES

CARRERA DE INGENIERIA EN SOFTWARE



ASIGNATURA:
INTELIGENCIA DE NEGOCIOS

TEMA:
TRABAJO

ELABORADO POR:
ANDY BRYAN ALEJANDRO VERA
REYES RICARDO ALISSON
RIVERA TORRES YANDRIS

CURSO Y PARALELO:
SOFTWARE 6/1

DOCENTE:
ING. ANTHONY ABRAHAN PACHAY ESPINOZA

LA LIBERTAD – ECUADOR

Entregable 3: Pipeline de Datos y Calidad

VI Inteligencia de Negocios · Ingeniería de Software · UPSE

1.- Arquitectura del Pipeline y flujo de datos

El pipeline ETL está diseñado e implementado en TypeScript/Node.js. Procesa datos de 4 tipologías de origen heterogéneas, consolidándolos a través de capas inmutables (raw) y de transformación (staging), y ejecutando un motor de validación de calidad de datos pragmático antes de su puesta a punto para el data Warehouse.

2. Ingestión y Extracción MultiFuente

Se ha implementado el consumo y almacenamiento directo de datos crudos en la zona Raw sin ningún tipo de preprocesamiento respetando los estándares de inmutabilidad y auditoría.

Web Scraping

- **MercadoLibreEcuador:** implementa Playwright headless para emular navegación humana, aplicación delays aleatorios preventivos de 3 a 6 segundos y cabeceras personalizadas de User-Agent.
- **AliExpress (aliexpress.ts):** Usa Playwright apuntando a books.toscrape.com como homólogo técnico sin bloqueos de firewall, extrayendo libros de prueba con sus correspondientes categorizaciones.
- **Temu (temu.ts) y Shein (shein.ts):** Utilizan un mecanismo híbrido documentado. Dado que incorporan firewalls perimetrales avanzados (Cloudflare Bot Management), se extraen mediante la Extensión de Chrome del proyecto dentro de la sesión activa del usuario para garantizar portabilidad. Los scripts del pipeline importan estos JSONs crudos simulando el guardado directo en la carpeta Raw.

Consumo de API

ExchangeRate API v6 (exchangerates.ts): Automatiza la descarga diaria de las tasas de conversión cambiaria en formato JSON.* Endpoint: <https://v6.exchangerate-api.com/v6/{KEY}/latest/USD>

- Autenticación: API Key gratuita (Tier Libre).
- Parámetros: base=USD.
- Registros obtenidos: 160 tasas de cambio con marca de tiempo persistente.

Archivo Estructurado

Kaggle E-Commerce Dataset (load_csv.ts): Ingesta un archivo CSV (dataset_original.csv) que simula transacciones e inventarios de comercio electrónico. El cargador lee el archivo, valida su volumen (filas y columnas) y realiza una validación básica de esquema antes de guardarlo en formato JSON inmutable en Raw.

Fuente Propia

Encuesta de Preferencias de Consumo (load_encuesta.ts): Procesamiento del Google Form recolectado por el equipo de desarrollo.* Metodología: Carga del CSV exportado (encuesta_raw.csv).

- Consideraciones Éticas: Purgado programático e inmediato de campos identificativos (Timestamp, nombre, email, correo, Marca temporal) antes de cualquier persistencia en Raw para garantizar privacidad de acuerdo con la Ley de Protección de Datos Personales.

3. Gobernanza y capa Raw

Los archivos se almacenan en carpetas organizadas cronológicamente bajo la nomenclatura fuente_YYYY-MM-DD.json. A continuación, se detalla la evidencia técnica de la zona Raw tras la ejecución del pipeline del 30 de junio de 2026:

Origen / Fuente	Archivo Generado en Raw	Registros Crudos	Tamaño del Archivo	Fecha de Extracción
MercadoLibre	mercadolibre_2026-06-30.json	15	4.1 KB	2026-06-30 02:44
AliExpress	aliexpress_2026-06-30.json	56	15.7KB	2026-06-30 02:44
Temu	temu_2026-06-30.json	30	16.7KB	2026-06-30 02:44
Shein	shein_2026-06-30.json	30	11.9KB	2026-06-30 02:44
ExchangeRate API	exchangerates_2026-06-30.json	162	41.6KB	2026-06-30 02:44
Dataset Kaggle (CSV)	dataset_2026-06-30.json	50	3.8KB	2026-06-30 02:44
Encuesta Forms (CSV)	encuesta_2026-06-30.json	25	1.8KB	2026-06-30 02:44

4. Procesamiento en staging.

El script `run_all.ts` coordina la carga del dato crudo y ejecuta modularmente las siguientes transformaciones críticas:

1. Homologación de nombres (`stg_normalize_columns.ts`): Mapea esquemas de origen heterogéneos a un esquema canónico estándar.
 - a. **title** (MercadoLibre) = **product_title** (AliExpress) = **nombre** (Temu) = **titulo** (Shein) -> **titulo_oferta** (Staging).
 - b. **price** (MercadoLibre) = **sale_price** (AliExpress) = **precio** (Shein/Temu) -> **precio_raw** (Staging).
2. Estandarización de fechas (`stg_dates.ts`): Conversión unificada de timestamps y strings de fechas al formato estándar ANSI YYYY-MM-DD.
3. Conversión de monedas (`stg_currency.ts`): Los precios capturados en otras divisas (como GBP de AliExpress, EUR, etc.) se limpian y convierten a USD de manera dinámica utilizando las tasas de conversión provistas por la API de ExchangeRates guardada ese mismo día en Raw.
4. Clasificación de categorías (`stg_classify.ts`): Asigna categorías maestras (electronica, ropa, hogar, belleza, deportes, juguetes) mediante la coincidencia de tokens y palabras clave en los títulos.
5. Deduplicación integral en Staging (`stg_dedup.ts`): Elimina registros duplicados a nivel de fuente basándose en claves primarias compuestas (`titulo_oferta + precio_raw + _fuente`).
 - a. *Resultados*: Se eliminaron 59 duplicados de productos y 1 duplicado de encuesta en esta capa.

5. Procesamiento en staging.

Este componente valida y limpia cuantitativamente los datos consolidados en Staging utilizando reglas de negocio estrictas.

Duplicados

Se define como duplicidad la coincidencia exacta de `titulo_oferta + precio_raw + _fuente` en productos, y de todos los campos en la encuesta. El Framework de Calidad re-evalúa y descarta duplicados remanentes. Se consolida el histórico de eliminaciones para la reconciliación del volumen.

Control de Nulos y Matriz de Imputación

Se analizan los campos clave identificando su origen y aplicando estrategias estadísticas o de negocio:

- **precio_raw** (MercadoLibre - 36.5% Nulos): Imputado con la mediana de precios de la categoría correspondiente.

- **titulo_oferta** (AliExpress - 1.2% Nulos): Nulo Crítico. Se purga el registro completo para evitar la propagación de datos corruptos al Data Warehouse.
- **categoria** (Temu - 42.9% Nulos): Se clasifica programáticamente usando el tokenizador de keywords de stg_classify.ts.
- **gasto_promedio_mensual** (Encuesta - 0.0% Nulos): Imputación contextual o exclusión en caso de valores vacíos.
- **edad** (Encuesta - 0.0% Nulos): Nulo Crítico. Eliminación directa si el participante no registró su edad.

Formatos y Casting de Precios

Se procesan expresiones regulares para convertir strings sucios en valores numéricos puros de precisión flotante:

- *Antes*: "£47.82", "USD 199.99", "€349.99", "\$150k".
- *Después*: 47.82, 199.99, 349.99, 150000.00 (guardados como tipo float/Decimal en la base de datos).

Estandarización Estricta

Se normalizan todos los strings eliminando espacios en blanco en extremos y convirtiéndolos a codificación UTF-8 Unicode Normalization Form C (NFC) para prevenir problemas sintácticos en los campos de la base de datos relacional.

Bitácora de Errores

Los errores detectados se registran de forma auditable en logs/pipeline_errors.log bajo la estructura estándar:

```
2026-06-30 07:44:03,aliexpress,FormatoInvalido,"precio no parseable: ""null""","Campo nulificado"
2026-06-30 07:44:03,aliexpress,NuloCritico,"Campo titulo_oferta nulo en 2 registros","Registros
purgados de inmediato"
```

6. Procesamiento en staging.

El reporte estadístico unificado coincide con los registros crudos de la capa Raw, las eliminaciones del Framework y los registros listos en Staging:

Métrica Operacional	Valor Numérico Real	Proporción relativa
Total, registros crudos procesados	206	100%
Total, registros consolidados aptos para DW	192	93.2%
Tasa de completitud general	93.2%	-
Registros depurados por duplicados	12	5.8%
Registros eliminados por nulos criticos	2	1%

Tasa de error promedio general	6.8%	
--------------------------------	------	--

Reconciliación Matemática de Flujos:

Conteo de Registros

- Registros Raw: 206
- Duplicados removidos: 12
- Nulos críticos removidos: 2
- Registros en Staging Aptos: 192

Métricas de Calidad

- Completitud: 93.2%
- Tasa de Error: 6.8%
- Total: 100.0%

Desglose de Tasa de Error Específica por Fuente:

- MercadoLibre: 13.3% (registros duplicados y nulos de precio imputados)
- AliExpress: 3.6% (registros purgados por títulos nulos)
- Temu: 0.0%
- Shein: 0.0%
- Dataset Kaggle (Archivos): 20.0% (precios sucios depurados y nulos clasificados)
- Encuesta (Fuente Propia): 4.0% (duplicado de respuestas removido)

Repositorio del código: <https://github.com/yan2005dris-afk/WebScrapingDinamico-Automatico>