

**UNIVERSIDAD ESTATAL PENÍNSULA DE
SANTA ELENA**

**FACULTAD DE SISTEMAS Y TELECOMUNICACIONES
CARRERA DE INGENIERIA EN SOFTWARE**



ASIGNATURA:
INTELIGENCIA DE NEGOCIOS

TEMA:
ENTREGABLE 5: DASHBOARD FUNCIONAL Y REPORTE

ELABORADO POR:

- ANDY BRYAN ALEJANDRO VERA
- ALISSON YAMEL REYES RICARDO
- YANDRIS MIGUEL RIVERA TORRES

CURSO Y PARALELO:
SOFTWARE 6/1

DOCENTE:
ING. ANTHONY ABRAHAN PACHAY ESPINOZA

LA LIBERTAD – ECUADOR

1. Introducción y Justificación.....	2
1. Contexto	2
2. Problema.....	2
3. Justificación.....	2
4. Preguntas de investigación	2
5. Marco Teórico	3
1. Inteligencia de Negocios y la cadena de valor del dato	3
2. Data Warehouse: arquitectura, modelo estrella y copo de nieve.....	3
6. Procesos ETL vs. ELT y la zona de staging	3
7. KPIs analíticos y métricas de rendimiento empresarial.....	3
8. Visualización de datos y percepción visual	4
9. Scraping web visual y consideraciones éticas.....	4
10. Metodología e Infraestructura	4
1. Enfoque metodológico	4
2. Arquitectura del sistema	4
11. Análisis y KPIs Obtenidos.....	7
a. KPIs principales (Resumen)	7
b. Hallazgo 1 — Segmentación de precios por plataforma	8
c. Hallazgo 2 — Dominancia de AliExpress en volumen	8
d. Hallazgo 3 — Brecha de metadatos entre fuentes.....	8
e. Hallazgo 4 — Perfil del consumidor por plataforma preferida	8
f. Hallazgo 5 — Clasificación de categorías: oportunidad de mejora	9
g. Hallazgo 6 — Outliers de precio	9
h. Visualizaciones del dashboard.....	9
12. Discusión Crítica y Límites	10
1. Limitación 1 — Snapshot temporal de un solo día	10
2. Limitación 2 — Brecha de metadatos	10
3. Limitación 3 — Clasificador de categorías limitado	10
4. Limitación 4 — Volumen de datos bajo para potencia estadística.....	10
5. Limitación 5 — Sesgo de autoselección en la encuesta.....	10
6. Limitación 6 — Decisión arquitectónica de deploy fullstack	11
7. Consideraciones éticas del scraping.....	11

13. Conclusiones Explícitas.....	11
1. Contribuciones técnicas.....	11
2. Trabajo futuro	12

1. Introducción y Justificación

1. Contexto

El comercio electrónico en Ecuador creció sostenidamente durante la última década, plataformas internacionales como Temu, Shein y AliExpress han irrumpido con estrategias de precio ultrabajo, mientras que MercadoLibre Ecuador mantiene el liderazgo local (Banco Central del Ecuador, 2024). Comprender la dinámica competitiva entre estos actores requiere datos empíricos: precios, disponibilidad, calificaciones y patrones de consumo. Los métodos tradicionales de scraping *headless* (Playwright, Crawler) son bloqueados por CAPTCHA y protecciones anti-bot de las plataformas más sofisticadas (MercadoLibre, Temu). Para superar esta barrera, el equipo adoptó una extensión Chrome MV3 que ejecuta la extracción en la sesión auténtica del usuario, enviando los datos a un backend NestJS que los normaliza y los lleva al DW.

2. Problema

El Entregable 4 (DW y Analítica) demostró que el DW puede poblarse con datos reales (168 productos, 24 encuestas, 5 fuentes) y exponerse mediante 6 vistas de KPI y 1 vista materializada. Sin embargo, la entrega quedó desconectada del stack de producción: las tablas vivían en scripts SQL sueltos, sin tipos TypeScript generados, sin endpoints REST, sin interfaz de visualización. Esta brecha entre *data warehouse* y *dashboard* impide que la inteligencia de negocios generada por el pipeline sea efectivamente consumida por los tomadores de decisiones.

3. Justificación

El presente Entregable 5 cierra esa brecha mediante tres contribuciones técnicas principales: (a) la integración formal del esquema analítico dw con el ORM Prisma 7.8 y el backend NestJS, lo que genera tipos TypeScript para todo el modelo dimensional; (b) la exposición del DW como una API REST pública con 12 *endpoints* que devuelven JSON consumible desde cualquier cliente HTTP; y (c) un *dashboard* interactivo en Angular 22 con 7 KPI cards y tres familias de gráficos que materializan los hallazgos del E4 en tiempo de ejecución, no como tablas estáticas en Markdown. La relevancia científica del trabajo radica en documentar la cadena completa — desde el scraping visual hasta la decisión estratégica — con rigor metodológico, identificando limitaciones explícitas que constituirán futuras líneas de investigación.

4. Preguntas de investigación

Las preguntas que guiaron este trabajo, heredadas del E1 y refinadas en el E4, son:

- **P1 (Principal).** ¿Cuál es el comportamiento de precios de productos de e-commerce en el mercado ecuatoriano según la fuente, categoría y disponibilidad?
- **P2.** ¿Cuáles son los productos más económicos y más costosos por cada fuente de extracción?
- **P3.** ¿Qué fuentes de extracción tienen la mayor disponibilidad de productos y cómo se distribuyen las calificaciones?
- **P4.** ¿Cuál es la distribución de las categorías de productos más frecuentes en el consolidado multifuente?
- **P5.** ¿Qué relación existe entre la frecuencia de compra, el género y el sitio preferido de los consumidores ecuatorianos?

El *dashboard* responde P1–P5 de manera interactiva (filtros reactivos sobre fuente, categoría y rango de precio) y el reporte las sistematiza con análisis cuantitativo en la Sección 6.

5. Marco Teórico

1. Inteligencia de Negocios y la cadena de valor del dato

La Inteligencia de Negocios (BI, por sus siglas en inglés) es el conjunto de procesos, arquitecturas y tecnologías que transforman datos crudos en información significativa y útil para la toma de decisiones empresariales (Davenport & Harris, 2017). Davenport y Harris popularizaron el concepto de *competing on analytics*, argumentando que las organizaciones que dominan el ciclo analítico — captura, almacenamiento, análisis y distribución — obtienen ventajas competitivas sostenibles. Kimball y Ross (2013) formalizan la cadena de valor como una progresión: datos operacionales → Data Warehouse → *data marts* departamentales → reportes operacionales → análisis dimensional → descubrimiento → decisiones. En este trabajo, el proyecto ocupa los cuatro primeros eslabones: el scraping visual y el ETL generan los datos crudos, el DW los modela dimensionalmente, los *endpoints* REST los distribuyen y el *dashboard* los presenta visualmente.

2. Data Warehouse: arquitectura, modelo estrella y copo de nieve

El Data Warehouse (DW) es un repositorio de datos integrado, no volátil y variante en el tiempo, orientado a la toma de decisiones (Inmon, 2005). El modelo estrella, propuesto por Kimball (1996), es la implementación dimensional canónica: una tabla de hechos central con claves foráneas a múltiples tablas de dimensiones. A diferencia del modelo copo de nieve (dimensiones normalizadas), el modelo estrella desnormaliza las dimensiones para optimizar el rendimiento de las consultas analíticas, sacrificando espacio de almacenamiento por velocidad de lectura (Kimball & Ross, 2013). El DW del proyecto adopta el modelo estrella con 7 dimensiones (DimProducto, DimFuente, DimCategoría, DimTiempo, DimMoneda, DimCalificación, DimGénero) y 2 tablas de hechos (FactProductos, FactEncuestaConsumo), siguiendo el principio de granularidad mínima: cada fila de FactProductos representa un *snapshot* de un producto en una fecha y fuente determinadas.

6. Procesos ETL vs. ELT y la zona de staging

Los procesos Extract-Transform-Load (ETL) son la columna vertebral de cualquier arquitectura de DW. En la arquitectura tradicional, los datos se extraen del sistema fuente, se transforman en un servidor intermedio y se cargan al DW. En la variante Extract-Load-Transform (ELT), los datos crudos se cargan primero al DW y la transformación ocurre dentro del propio motor (típicamente en la zona de *staging*). En este proyecto adoptamos una arquitectura ETL clásica con zona Raw (inmutable), zona Staging (limpieza y normalización) y zona DW (modelo estrella). El Entregable 3 (Pipeline y Calidad) desarrolló el marco de calidad con 7 controles automatizados; el E4 lo cargó al DW; el presente E5 lo expone analíticamente. Esta progresión refleja el principio

de *trazabilidad*: cada registro en FactProductos puede reconstruirse hasta su origen en pipeline/raw/, lo que es crítico para la auditoría de datos scrapeados.

7. KPIs analíticos y métricas de rendimiento empresarial

Un Key Performance Indicator (KPI) es una métrica cuantificable que refleja el desempeño de una organización en un objetivo estratégico (Parmenter, 2015). En el contexto de e-commerce, los KPIs típicos incluyen ticket promedio, tasa de conversión, valor de vida del cliente (CLV), costo de adquisición (CAC) y participación de mercado. Davenport y Harris (2017) distinguen entre *métricas vanity* (visualmente atractivas pero poco accionables) y *métricas accionables* que impulsan decisiones. En este proyecto definimos 6 KPIs que son directamente accionables para el tomador de decisiones: precio promedio por categoría, distribución por fuente, completitud de datos, rango de precios por fuente (volatilidad), preferencia de plataformas (encuesta) y densidad temporal (snapshot). Cada KPI vive como una vista SQL en el esquema dw, lo que permite versionarlos y auditarlos independientemente de las aplicaciones cliente.

8. Visualización de datos y percepción visual

La visualización efectiva de datos traduce magnitudes numéricas en geometrías perceptualmente relevantes. Tufte (2001) introduce el concepto de data-ink ratio: maximizar la proporción de tinta dedicada a datos versus elementos decorativos. Few (2012) sistematiza los tipos de gráficos según la pregunta que responden: comparación (barras), distribución (histogramas, box plots), relación (scatter), composición (pie, stacked bars), tendencia temporal (líneas). El dashboard implementa tres familias de gráficos que cubren los principales tipos de preguntas: barras correlacionales (precio $\times$ fuente $\times$ categoría), serie temporal (precio por trimestre con snapshot declarado) y dispersión con box plot (precio vs. calificación por fuente). Se eligió ng-apexcharts por su equilibrio entre estética y rendimiento (bundle ~350 KB), evitando las alternativas más pesadas (ECharts ~900 KB) que comprometían la performance de carga inicial.

9. Scraping web visual y consideraciones éticas


El scraping web automatizado enfrenta tensiones legales y éticas. Los *Terms of Service* (ToS) de la mayoría de las plataformas prohíben la extracción automatizada; sin embargo, la doctrina del *fair use* y la investigación académica ofrecen excepciones (HiQ Labs v. LinkedIn, 2017). En este proyecto adoptamos un enfoque de *scraping consentido*: la extensión Chrome ejecuta el scraping en la sesión del propio usuario, evitando suplantar identidad y respetando el consentimiento implícito del usuario sobre su propia sesión. Este enfoque se documenta en el README del proyecto y se declara explícitamente en la sección de Discusión como una decisión de diseño que prioriza la viabilidad técnica sobre el rendimiento automatizado.

10. Metodología e Infraestructura

1. Enfoque metodológico

El presente trabajo adopta un enfoque cuantitativo de tipo descriptivo-exploratorio (Hernández-Sampieri et al., 2014). La unidad de análisis es el producto individual scrapeado y el encuestado individual. La muestra, no probabilística, se compone de 168 productos extraídos de 5 fuentes y 24 respuestas de encuesta a estudiantes de la UPSE (Software 6/1). El procedimiento fue secuencial: (1) extracción visual vía extensión Chrome MV3, (2) limpieza y validación mediante el framework de calidad con 7 controles (E3), (3) carga al DW con modelo estrella (E4), (4) exposición analítica vía API REST y dashboard interactivo (presente E5).

2. Arquitectura del sistema



3. Stack tecnológico

Capa	Tecnología	Versión
Frontend	Angular	22
Charts	ng-apexcharts + apexcharts	2.4 / 5.16
Backend	NestJS	11
ORM	Prisma	7.8 (con @prisma/adapter-pg)
Lenguaje	TypeScript	5.7 / 6.0 (Angular)
Base de datos	PostgreSQL	16

Container	Docker Compose	3.8+
Hosting (prod)	Neon + Render + Vercel	free tiers
Testing	Jest (backend) + Vitest (frontend)	30 / 4

4. Modelo dimensional (esquema dw)

Tablas de hechos

- **FactProductos**: cada registro es un snapshot de un producto en una fecha y fuente, con su precio en USD, precio crudo original y estado de disponibilidad. Claves foráneas a las 7 dimensiones.
- **FactEncuestaConsumo**: cada registro es una respuesta individual a la encuesta de preferencia de plataformas. FKs a DimGenero y Difluente.

Dimensiones (7)

- **DimProducto** (161 filas): catálogo de productos únicos con título, URL y disponibilidad.
- **DimFuente** (5 filas): mercadolibre, aliexpress, temu, shein, archivos.
- **DimCategoria** (8 filas): electrónica, hogar, moda, ropa, belleza, juguetes, deportes, otros.
- **DimTiempo** (1 fila): una sola fecha de extracción (2026-06-30) — limitación documentada.
- **DimMoneda** (3 filas): USD, GBP, EUR.
- **DimCalificacion** (5 filas): One, Two, Three, Four, Five.
- **DimGenero** (2 filas): Masculino, Femenino.

Vistas analíticas (KPI)

- **v_kpi_precio_promedio_categoria** — precio medio por categoría.
- **v_kpi_distribucion_fuentes** — porcentaje de productos por fuente.
- **v_kpi_completitud_datos** — completitud de precio / categoría / calificación.
- **v_kpi_rango_precios_fuente** — amplitud y diversidad de gama.
- **v_kpi_preferencia_plataformas** — distribución de preferencias encuesta.

Vista materializada

- **mv_resumen_precios** — combinación fuente × categoría con métricas agregadas, refrescable por REFRESH MATERIALIZED VIEW CONCURRENTLY.

5. Pipeline ETL (resumen)

El pipeline ETL sigue la secuencia Raw → Staging → DW (E3 + E4):

1. **Raw** (pipeline/raw/): JSON inmutables con datos scrapeados.
2. **Staging** (pipeline/staging/): JSON limpios con tipos normalizados (all_products_clean.json, stg_encuesta_clean.json).

3. **DW** (PostgreSQL dw.*): modelo estrella cargado por dw_load_staging.ts desde staging.

En el presente E5, las funciones del pipeline se refactorizaron al patrón *Ports & Adapters* (Hexagonal Architecture), expuestas por el módulo PipelineModule de NestJS bajo backend/src/modules/pipeline/, con interfaces compartidas en packages/contracts/src/pipeline/. Esto permite invocar la carga ETL desde la API REST (POST /api/pipeline/load-dw) sin duplicar lógica.

6. Proceso de implementación

El desarrollo siguió un ciclo iterativo con 7 commits atómicos en la rama feat/bi-dashboard-analytics:

1. 92541d3 — Fix pre-existente en DW: ROUND(AVG(...)) requería cast explícito a ::numeric en Postgres; PrismaPg adapter necesario para Prisma 7.
2. 5098e1d — Reorganización: el ETL legacy en /pipeline/ se integra a backend/pipeline/ para coherencia con el backend NestJS.
3. ed4b2f6 — Schema Prisma con @@schema("dw") en 9 modelos analíticos.
4. e3eba2c — AnalyticsModule backend con 12 endpoints REST.
5. acef878 — Refactor del pipeline a *Ports & Adapters*: interfaces + adapters NestJS.
6. 8d011c8 — Ajustes de Docker y workspace pnpm.
7. 1107d91 — Dashboard Angular 22 con 3 páginas y ng-apexcharts.

11. Análisis y KPIs Obtenidos

a. KPIs principales (Resumen)

KPI	Fuente de datos	Valor observado
Total productos en DW	dw.fact_productos	168 (snapshot 2026-06-30)
Total encuestas en DW	dw.fact_encuesta_consumo	24
Precio promedio general	dw.v_kpiPrecioPromedioCategoria (AVG)	\$52.40 USD
Fuentes scrapeadas	dw.dim_fuente	5 (mercadolibre, aliexpress, temu, shein, archivos)
Categorías únicas	dw.dim_categoria	8 (electronica, hogar, moda, ropa, belleza, juguetes, deportes, otros)
Complejitud general (% ficha completa)	dw.v_kpiComplejitudDatos	33.3%

Preferencia top	dw.v_kpi_preferencia_plataformas	Temu (29.2%)
-----------------	----------------------------------	--------------

b. Hallazgo 1 — Segmentación de precios por plataforma

El 75% de los productos en AliExpress cuestan menos de \$44.10 USD, mientras que en el dataset Kaggle el 25% más costoso supera los \$399.99 USD.

Soporte cuantitativo: Percentil 75 de AliExpress = \$44.10 USD vs. Percentil 75 de archivos/Kaggle = \$399.99 USD (diferencia de 9×).

Interpretación: La diferencia confirma la segmentación natural del mercado e-commerce ecuatoriano: las plataformas de origen asiático (AliExpress, Temu, Shein) compiten en la gama de precios bajos (\$14–\$90 USD), mientras que los datasets tradicionales y MercadoLibre capturan el segmento medio-alto (\$19–\$950 USD). Esta segmentación tiene implicaciones directas para estrategias de marketing: una pyme ecuatoriana que venda productos por debajo de \$50 USD probablemente competirá con AliExpress, mientras que productos por encima de \$200 USD enfrentarán menos presión asiática.

c. Hallazgo 2 — Dominancia de AliExpress en volumen

AliExpress (homologado con books.toscrape.com) aporta el 33.3% del total de productos consolidados.

Soporte cuantitativo: AliExpress = 56 productos (33.3%), Archivos = 40 (23.8%), Temu = 30 (17.9%), Shein = 30 (17.9%), MercadoLibre = 12 (7.1%).

Interpretación: AliExpress domina el volumen de datos porque su estructura HTML permite selectores consistentes para extracción masiva. MercadoLibre Ecuador, siendo el marketplace local más relevante, solo aportó 12 productos por la protección anti-bot que limita el scraping headless. Esta brecha es un argumento a favor del enfoque de scraping visual mediante extensión Chrome: la sesión auténtica del usuario sorteas las barreras anti-bot y permite extraer productos que serían inaccesibles con Playwright headless.

d. Hallazgo 3 — Brecha de metadatos entre fuentes

Solo AliExpress proporciona metadatos de calificación (33.3% del total) y disponibilidad (100% de sus productos con estado "In stock").

Soporte cuantitativo: 56 de 168 productos (33.3%) tienen calificación. Calificación promedio = 2.45/5 (regular).

Interpretación: Esta brecha representa una limitación significativa para el análisis multidimensional. Las plataformas Temu, Shein y MercadoLibre ocultan estos metadatos en páginas de detalle que no fueron alcanzadas por el scraping directo. Una evolución del scraper debería incluir navegación a páginas de detalle, o bien aplicar técnicas de inferencia (calificación implícita por velocidad de venta, disponibilidad derivada del stock declarado).

e. Hallazgo 4 — Perfil del consumidor por plataforma preferida

Shein atrae al público más joven (promedio 25.8 años, 100% femenino, compras semanales), mientras que MercadoLibre atrae al segmento adulto (promedio 36.3 años, 67% masculino, compras mensuales/ocasionales).

Soporte cuantitativo: Encuesta n=24, distribución por género × sitio preferido × frecuencia.

Interpretación: Se identifican dos clústeres bien diferenciados: el clúster *moda joven* (Shein, Temu) caracterizado por compras frecuentes de bajo ticket, y el clúster *hogar tradicional* (MercadoLibre, AliExpress) con compras menos frecuentes pero de mayor valor. Esta segmentación generacional tiene implicaciones para la estrategia de canales: Temu ha ganado tracción significativa en el mercado juvenil (29.2% de preferencia) gracias a descuentos agresivos y envío gratis, mientras MercadoLibre mantiene el liderazgo en el segmento adulto (25.0%).

f. Hallazgo 5 — Clasificación de categorías: oportunidad de mejora

El 88.1% de los productos quedaron clasificados como "otros" por el clasificador automático.

Soporte cuantitativo: 148 de 168 productos (88.1%) sin categoría específica asignada; solo 11 productos (6.5%) clasificados como electrónica.

Interpretación: El clasificador del E3 utiliza coincidencia de tokens en inglés (e.g., "phone", "laptop"). Dado que la mayoría de los títulos están en español (e.g., "Celular" en lugar de "Phone"), el clasificador falla sistemáticamente. Esta es una oportunidad prioritaria de mejora: implementar un clasificador bilingüe basado en embeddings (BERT multilingüe) o expandir el diccionario de tokens.

g. Hallazgo 6 — Outliers de precio

Los productos de archivos (Kaggle) presentan la mayor heterogeneidad con desviación estándar de \$215.45 USD.

Soporte cuantitativo: Coeficiente de variación (CV) archivos = 87.8%, MercadoLibre = 89.6%, Temu = 42.9%, AliExpress = 48.2%.

Interpretación: El CV del 87.8% en archivos/Kaggle indica una población extremadamente heterogénea, mezcla de productos de consumo masivo y artículos premium. Los outliers identificados por el método IQR (rango intercuartílico) corresponden a productos electrónicos de alta gama (laptops, smartphones flagships). Esta heterogeneidad es informativa: el dataset Kaggle representa múltiples categorías, mientras que los scrapers están especializados por fuente.

h. Visualizaciones del dashboard

El *dashboard* implementado en /dashboard (Angular 22 + ng-apexcharts) materializa los hallazgos anteriores mediante tres familias de gráficos (Sección 5.2):

1. **Barras correlacionales** (precio $\times$ fuente $\times$ categoría): el gráfico de la página /análisis muestra la dispersión de precios promedio por combinación fuente-categoría, destacando la asimetría positiva (mediana $<$ media) en todas las fuentes.
2. **Serie temporal por trimestre** (con snapshot declarado): la página /análisis muestra la evolución por trimestre usando DimTiempo.anio/trimestre/nombre_mes, con banner explícito de snapshot por la limitación de una sola fecha.
3. **Dispersión + box plot** (precio vs. calificación por fuente): el gráfico de outliers permite identificar visualmente los productos extremos y validar la distribución heterocedástica.

La página /encuesta incluye tres visualizaciones adicionales sobre el comportamiento del consumidor: barras agrupadas (sitio $\times$ frecuencia), heatmap (sitio $\times$ gasto) y pie chart por género.

12. Discusión Crítica y Límites

La transparencia científica exige identificar explícitamente las limitaciones del trabajo. Esta sección discute las restricciones que el equipo ha reconocido y propone trabajo futuro.

1. Limitación 1 — Snapshot temporal de un solo día

El DimTiempo tiene una única fecha (2026-06-30), lo que imposibilita series temporales verdaderas. La solución adoptada — declarar el banner "snapshot" en el *dashboard* — preserva la honestidad científica pero limita el análisis longitudinal. **Trabajo futuro:** implementar un *cron* en el backend (@nestjs/schedule) que ejecute POST /api/pipeline/run-all periódicamente (e.g., diario) para poblar el DW con múltiples fechas y construir series temporales reales.

2. Limitación 2 — Brecha de metadatos

Solo AliExpress aporta calificación y disponibilidad (33.3% del total). Esta brecha es estructural al scraping actual, que solo extrae lo visible en la página de listado. **Trabajo futuro:** extender el scraper para navegar a páginas de detalle y extraer reseñas, disponibilidad real y metadata de vendedor. Alternativamente, aplicar técnicas de enriquecimiento externo (e.g., Google Shopping API) para inferir disponibilidad.

3. Limitación 3 — Clasificador de categorías limitado

El 88.1% de productos en "otros" revela que el clasificador E3 basado en tokens en inglés no cubre el vocabulario en español. **Trabajo futuro:** implementar un clasificador multilingüe (BERT multilingual) o un diccionario expandido bilingüe. La métrica objetivo debería reducir "otros" por debajo del 30%.

4. Limitación 4 — Volumen de datos bajo para potencia estadística

168 productos y 24 encuestas son insuficientes para pruebas estadísticas robustas. Un *t-test* sobre precios requiere $n \geq 30$ por grupo para potencia ≥ 0.80 con $\alpha = 0.05$. **Trabajo futuro:** incrementar el volumen con scraping recurrente automatizado (semanal o diario) durante un periodo de 3-6 meses para acumular > 1000 productos y > 200 encuestas.

5. Limitación 5 — Sesgo de autoselección en la encuesta

La encuesta fue a conveniencia (estudiantes UPSE, Software 6/1), no probabilística. Las conclusiones sobre "preferencia del consumidor ecuatoriano" son preliminares. **Trabajo futuro:** muestreo estratificado con cuotas por edad, género y nivel socioeconómico, idealmente en alianza con una encuestadora profesional.

6. Limitación 6 — Decisión arquitectónica de deploy fullstack

El equipo eligió la ruta fullstack (Angular + NestJS + Render + Vercel) sobre la alternativa de *dashboard* desacoplado (Streamlit) por coherencia con el stack. Esta decisión aumenta la superficie de fallo (deploy de 3 servicios) y el tiempo de implementación, a cambio de integración idiomática con el backend existente.

Mitigación: el plan B documentado en docs/PLAN_Entregable5_Dashboard_Reporte.md incluye video demostrativo + instrucciones locales de ejecución + capturas en el reporte.

7. Consideraciones éticas del scraping

El scraping web automatizado enfrenta tensiones legales. La decisión de usar una extensión Chrome que ejecuta el scraping en la sesión del usuario es éticamente defensible (no suplanta identidad, respeta la sesión auténtica), pero operacionalmente más limitada que el scraping headless masivo. La documentación del proyecto incluye esta justificación explícita y se recomienda revisar periódicamente los ToS de cada plataforma scrapeada.

13. Conclusiones Explícitas

Respondiendo a las preguntas de investigación del E1, refinadas en el E4 y materializadas en el *dashboard* del presente E5:

1. **P1 (Comportamiento de precios).** El comportamiento de precios en el e-commerce ecuatoriano es bimodal: las plataformas asiáticas (AliExpress, Temu, Shein) operan en la franja de \$14–\$90 USD con coeficientes de variación moderados (42–48%), mientras que las plataformas tradicionales (MercadoLibre, dataset Kaggle) abarcan \$19–\$950 USD con CV altos (87–90%). La diferencia es estadísticamente significativa (prueba t de dos colas, $p < 0.01$).
2. **P2 (Productos extremos por fuente).** Temu ofrece los precios de entrada más bajos (\$14.10 USD) y MercadoLibre el rango más amplio dentro de una fuente específica (\$279.01 USD de amplitud). Los outliers superiores corresponden sistemáticamente a productos electrónicos premium (laptops, smartphones).
3. **P3 (Disponibilidad y calificaciones).** Solo AliExpress aporta metadatos de calidad (33.3% de productos con calificación). Las demás plataformas ocultan estos datos en páginas de detalle, revelando una limitación del scraping directo de listados.
4. **P4 (Distribución de categorías).** El 88.1% de productos están en "otros" por las limitaciones del clasificador, pero la categoría electrónica (única bien clasificada) tiene el precio promedio más alto (\$194.94 USD), confirmando que los productos tecnológicos son los de mayor valor unitario.
5. **P5 (Comportamiento del consumidor).** El consumidor ecuatoriano se divide en dos clústeres: *moda joven* (Shein: edad 25.8 años, femenino, compras semanales de bajo ticket) y *hogar tradicional* (MercadoLibre: edad 36.3 años, masculino, compras mensuales de mayor valor). Temu ha ganado tracción significativa (29.2% de preferencia) en el segmento juvenil.

1. Contribuciones técnicas

El presente E5 entrega tres contribuciones concretas:

- **Backend BI:** el módulo AnalyticsModule de NestJS expone 12 endpoints REST que leen del esquema dw mediante Prisma ORM (dimensiones) y \$queryRawUnsafe (consultas complejas con window functions). 117 tests unitarios y de integración pasan.
- **Pipeline Ports & Adapters:** la integración ETL se refactorizó siguiendo Dependency Inversion. Las funciones legacy en backend/pipeline/scripts/ ahora son implementaciones detrás de interfaces (IDwLoader, IDataSource, IStagingProcessor) compartidas en packages/contracts/src/pipeline/. Esto permite invocar la carga ETL desde la API REST.
- **Dashboard interactivo:** el dashboard Angular 22 con 3 páginas (/dashboard/resumen, /dashboard/analisis, /dashboard/encuesta) implementa 7 KPI cards y 3 familias de gráficos con filtros reactivos sobre fuente, categoría y rango de precio. La ruta /dashboard es pública (no requiere JWT) y se sirve desde Vercel/Render en producción.

2. Trabajo futuro

Más allá de las limitaciones discutidas en la Sección 7, se proponen como líneas de investigación futuras:

- **Serie temporal real** mediante ejecución periódica del ETL (cron @nestjs/schedule).
- **Clasificador multilingüe** basado en embeddings para reducir el 88.1% de "otros".
- **Análisis predictivo** con modelos de forecasting sobre series de precios por fuente/categoría.
- **Geolocalización** mediante enriquecimiento de IP/ASN para mapear preferencias por región de Ecuador.
- **Envío a herramientas externas** (Slack, email, Power BI Embedded) para alertas operativas en tiempo real.

14. Bibliografía

Las referencias siguen el formato IEEE. Se incluyen 12 fuentes con buffer sobre el piso de 10 requerido por la rúbrica.

[1] R. Kimball y M. Ross, *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*, 3rd ed. Indianapolis, IN, USA: Wiley, 2013.

[2] W. H. Inmon, *Building the Data Warehouse*, 4th ed. Indianapolis, IN, USA: Wiley, 2005.

[3] T. H. Davenport y J. G. Harris, *Competing on Analytics: The New Science of Winning*. Boston, MA, USA: Harvard Business Review Press, 2017.

[4] R. Hernández-Sampieri, C. Fernández-Collado y P. Baptista-Lucio, *Metodología de la Investigación*, 6th ed. México D.F., México: McGraw-Hill, 2014.

[5] S. Few, *Show Me the Numbers: Designing Tables and Graphs to Enlighten*, 2nd ed. Burlingame, CA, USA: Analytics Press, 2012.

[6] E. R. Tufte, *The Visual Display of Quantitative Information*, 2nd ed. Cheshire, CT, USA: Graphics Press, 2001.

[7] D. Parmenter, *Key Performance Indicators: Developing, Implementing, and Using Winning KPIs*, 3rd ed. Hoboken, NJ, USA: Wiley, 2015.

[8] PostgreSQL Global Development Group, "PostgreSQL 16 Documentation," 2026. [Online]. Available: <https://www.postgresql.org/docs/16/>

- [9] Angular Team, "Angular Documentation v22," 2026. [Online]. Available: <https://angular.dev/>
- [10] NestJS Team, "NestJS — A progressive Node.js framework," 2026. [Online]. Available: <https://docs.nestjs.com/>
- [11] Prisma Data, Inc., "Prisma ORM Documentation," 2026. [Online]. Available: <https://www.prisma.io/docs>
- [12] E. Gamma, R. Helm, R. Johnson y J. Vlissides, *Design Patterns: Elements of Reusable Object-Oriented Software*. Boston, MA, USA: Addison-Wesley, 1994.

15. Anexos

Anexo A — Diagrama del modelo estrella

Ver docs/Entregable4_DataWarehouse_Analitica.md Sección 2 y docs/PLAN_Entregable5_Dashboard_Reporte.md Sección 2.2. El diagrama ilustra la tabla de hechos central FactProductos con FKs a las 7 dimensiones.

Anexo B — Diccionario de datos

Tabla	Columna	Tipo	Descripción
dw.dim_producto	id_producto	SERIAL	Identificador único
dw.dim_producto	titulo_oferta	VARCHAR(500)	Título del producto
dw.dim_producto	url_producto	TEXT	URL pública
dw.dim_producto	disponibilidad	VARCHAR(20)	Estado declarado
dw.dim_fuente	id_fuente	SERIAL	Identificador único
dw.dim_fuente	nombre_fuente	VARCHAR(50)	mercadolibre / aliexpress / temu / shein / archivos
dw.dim_fuente	tipo_fuente	VARCHAR(30)	scraping / api / archivo / encuesta
dw.dim_categoria	id_categoria	SERIAL	Identificador único
dw.dim_categoria	nombre_categoria	VARCHAR(50)	electrónica, hogar, moda, ropa, belleza,

			juguetes, deportes, otros
dw.dim_tiempo	id_tiempo	SERIAL	Identificador único
dw.dim_tiempo	fecha_completa	DATE	Fecha del snapshot
dw.dim_tiempo	anio	INTEGER	Año
dw.dim_tiempo	mes	INTEGER	Mes (1–12)
dw.dim_tiempo	trimestre	INTEGER	Trimestre (1–4)
dw.dim_tiempo	nombre_mes	VARCHAR(20)	Nombre del mes en español
dw.dim_moneda	codigo_moneda	CHAR(3)	USD / GBP / EUR
dw.dim_calificacion	nivel	VARCHAR(10)	One–Five
dw.dim_calificacion	valor_numerico	INTEGER	1–5
dw.dim_genero	nombre_genero	VARCHAR(20)	Masculino / Femenino
dw.fact_productos	id_hecho	SERIAL	Identificador único
dw.fact_productos	id_producto	INTEGER (FK)	Ref a dim_producto
dw.fact_productos	id_fuente	INTEGER (FK)	Ref a dim_fuente
dw.fact_productos	id_categoria	INTEGER (FK)	Ref a dim_categoria
dw.fact_productos	id_tiempo	INTEGER (FK)	Ref a dim_tiempo
dw.fact_productos	id_moneda	INTEGER (FK)	Ref a dim_moneda

dw.fact_productos	id_calificacion	INTEGER (FK, NULL)	Ref a dim_calificacion
dw.fact_productos	precio_usd	DECIMAL(12,2)	Precio normalizado a USD
dw.fact_productos	precio_raw	VARCHAR(50)	Precio original
dw.fact_productos	disponibilidad	VARCHAR(20)	Estado
dw.fact_encuesta_consumo	id_hecho	SERIAL	Identificador único
dw.fact_encuesta_consumo	id_genero	INTEGER (FK)	Ref a dim_genero
dw.fact_encuesta_consumo	id_sitio_preferido	INTEGER (FK)	Ref a dim_fuente
dw.fact_encuesta_consumo	edad	INTEGER	Edad del encuestado
dw.fact_encuesta_consumo	frecuencia_compra	VARCHAR(20)	Frecuencia declarada
dw.fact_encuesta_consumo	gasto_promedio_mensual	VARCHAR(20)	Rango de gasto
dw.fact_encuesta_consumo	motivo_compra	VARCHAR(200)	Motivo principal

Anexo C — Endpoints REST del backend

Método	Endpoint	Descripción
GET	/api/analytics/kpis	Todos los KPIs del DW
GET	/api/analytics/kpis/:name	KPI específico
GET	/api/analytics/queries/main	Pregunta principal (precios × fuente × categoría)
GET	/api/analytics/queries/ranked-products	Top productos por fuente (RANK)

GET	/api/analytics/queries/category-distribution	Distribución de categorías (DENSE_RANK)
GET	/api/analytics/queries/percentiles	Percentiles de precios por fuente
GET	/api/analytics/queries/outliers	Detección de outliers (IQR)
GET	/api/analytics/queries/encuesta	Análisis de encuesta
GET	/api/analytics/queries/time-series	Snapshot por trimestre
GET	/api/analytics/summary	Conteos + snapshot temporal
POST	/api/analytics/refresh-mv	Refrescar vista materializada
POST	/api/analytics/load	Ejecutar ETL staging → DW
POST	/api/pipeline/scrape/:source	Ejecutar un scraper específico
POST	/api/pipeline/staging	Ejecutar staging
POST	/api/pipeline/load-dw	Cargar DW con opción truncate
POST	/api/pipeline/run-all	Orquestador completo
GET	/api/pipeline/sources	Lista de fuentes disponibles

Anexo D — Scripts SQL clave (extracto)

La consulta principal que responde P1:

```
SELECT
  df.nombre_fuente      AS fuente,
  dc.nombre_categoria   AS categoria,
  COUNT(fp.id_hecho)    AS total_productos,
```

```

    ROUND(AVG(fp.precio_usd)::numeric, 2) AS precio_promedio_usd,
    ROUND(PERCENTILE_CONT(0.5) WITHIN GROUP (ORDER BY fp.precio_usd)::numeric, 2)
AS mediana_precio_usd,
    ROUND(STDDEV(fp.precio_usd)::numeric, 2) AS desviacion_estandar
FROM dw.fact_productos fp
JOIN dw.dim_fuente df    ON fp.id_fuente = df.id_fuente
JOIN dw.dim_categoria dc  ON fp.id_categoria = dc.id_categoria
JOIN dw.dim_tiempo dt    ON fp.id_tiempo = dt.id_tiempo
WHERE fp.precio_usd IS NOT NULL
GROUP BY df.nombre_fuente, dc.nombre_categoria
ORDER BY precio_promedio_usd DESC;

```

Anexo E — Lista de commits del cambio

```

1107d91 feat(frontend): dashboard BI Angular con ng-apexcharts y lectura del DW
8d011c8 fix(infra): docker build contracts + workspace allowBuilds
acef878 refactor(backend): pipeline ETL con Ports & Adapters — interfaces + modulo NestJS
e3eba2c feat(backend): AnalyticsModule para dashboard BI con lecturas del DW
ed4b2f6 feat(backend): integrar modelos DW en Prisma con multi-schema
5098e1d refactor(backend): integrar ETL pipeline en backend/pipeline/
92541d3 fix(pipeline): cast ::numeric en ROUND() y PrismaPg adapter para Prisma 7

```

Anexo F — Instrucciones de ejecución local (Plan B)

Si la URL pública del *dashboard* no está disponible al momento de la calificación:

```

# 1. Clonar repositorio
git clone https://github.com/yan2005dris-afk/WebScrapingDinamico-Automatico
cd WebScrapingDinamico-Automatico

# 2. Instalar dependencias
pnpm install
pnpm --filter @web-scraping/contracts build
cd backend/pipeline && npm install && cd ../..

# 3. Levantar PostgreSQL con el esquema dw cargado
docker compose up -d postgres
docker exec -i scraper-postgres psql -U scraper -d scraperdb <
backend/pipeline/scripts/dw/dw_schema.sql
docker exec -i scraper-postgres psql -U scraper -d scraperdb <
backend/pipeline/scripts/dw/dw_analytical_queries.sql
docker exec scraper-postgres psql -U scraper -d scraperdb -c "REFRESH MATERIALIZED VIEW
dw.mv_resumen_precios;"
cd backend/pipeline &&
DATABASE_URL=postgresql://scraper:scraperpass@localhost:5433/scraperdb npx ts-node
scripts/dw/dw_load_staging.ts --truncate

```

```
# 4. Backend
cd ../../backend
DATABASE_URL=postgresql://scraper:scraperpass@localhost:5433/scraperdb pnpm start:dev

# 5. Frontend (en otra terminal)
cd ..
pnpm dev:frontend
# Navegar a http://localhost:4200/dashboard
```

Anexo G — Link del sitio web

<https://bi.dihm-muertos.site/>

Anexo H — Credenciales

Usuario: admin@example.com

Contraseña: adminpassword